

机器学习讨论班

2018年暑期

6. 支持向量机

丁金如

介绍内容

- 支持向量机SVM的原理和目标
- 线性可分支持向量机
- 线性支持向量机
- 非线性支持向量机
- 实验：手写体识别

基本概念


二次规划:一类典型的优化问题。在此类问题中, 目标函数是变量的二次函数, 而约束条件是变量的线性不等式。

SVM: 通俗来讲, 它是一种二类分类模型, 其基本模型定义为特征空间上的间隔最大的线性分类器, 其学习策略便是间隔最大化, 最终可转化为一个凸二次规划问题的求解。

输入: 训练样本集 $D = \{(x_1, y_1), \dots, (x_m, y_m), \}$, $y_i \in \{-1, +1\}$

输出: 超平面 $\mathbf{w}^T \mathbf{x} + b = 0$

分类决策函数: $f(x) = \text{sign}(\mathbf{w}^T \mathbf{x} + b)$



SVM模型

- 线性可分支持向量机
 - 硬间隔最大化
 - 硬间隔支持向量机
- 线性支持向量机
 - 软间隔最大化
 - 软间隔支持向量机
- 非线性支持向量机
 - 核函数

线性可分支持向量机

- 给定线性可分训练数据集，通过间隔最大化得到的分离超平面为

$$y(x) = w^T \varphi(x) + b$$

相应的分类决策函数 $f(x) = \text{sign}(w^T \varphi(x) + b)$

该决策函数称为线性可分支持向量机。

- $\varphi(x)$ 是某个确定的特征空间转换函数，它的作用是将 x 映射到(更高的)维度。


□ 最简单的映射： $\varphi(x) = x$

如何寻找最大间隔超平面？

$$\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$$

目标函数：

$$\arg \max_{w,b} \left\{ \frac{1}{\|w\|} \min_i [y_i \cdot (w^T \cdot \varphi(x_i) + b)] \right\}$$



建立目标函数

■ 总可以通过等比例缩放的方法，使得两类点的函数值都满足 $|y| \geq 1$

■ 约束条件： $y_i \cdot (w^T \cdot \varphi(x_i) + b) \geq 1$

■ 原目标函数：

$$\arg \max_{w,b} \left\{ \frac{1}{\|w\|} \min_i [y_i \cdot (w^T \cdot \varphi(x_i) + b)] \right\}$$

■ 新目标函数：

$$\arg \max_{w,b} \frac{1}{\|w\|}$$

建立目标函数

$$\arg \max_{w,b} \frac{1}{\|w\|}$$

$$s.t. \quad y_i(w^T \cdot \varphi(x_i) + b) \geq 1, i = 1, 2, \dots, n$$

$$\arg \min_{w,b} \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w^T \cdot \varphi(x_i) + b) \geq 1, i = 1, 2, \dots, n$$

如何求解目标函数？ [拉格朗日乘子法](#)

$$\arg \min_{w,b} \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w^T \cdot \varphi(x_i) + b) \geq 1, i = 1, 2, \dots, n$$

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i(w^T \cdot \varphi(x_i) + b) - 1)$$

- 原问题是极小极大问题 $\min_{w,b} \max_{\alpha} L(w, b, \alpha)$
- 原始问题的对偶问题，是极大极小问题 $\max_{\alpha} \min_{w,b} L(w, b, \alpha)$

拉格朗日函数

将拉格朗日函数 $L(\mathbf{w}, b, \alpha)$ 分别对求偏导，并令其为0：

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \varphi(x_i)$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow 0 = \sum_{i=1}^n \alpha_i y_i$$

计算拉格朗日函数的对偶函数

$$w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$$

$$0 = \sum_{i=1}^n \alpha_i y_i$$

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T \cdot \Phi(x_i) + b) - 1)$$

$$= \frac{1}{2} w^T w - w^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i) - b \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i$$

$$= \frac{1}{2} w^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i) - w^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i) - b \cdot 0 + \sum_{i=1}^n \alpha_i$$

$$= \sum_{i=1}^n \alpha_i - \frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i \Phi(x_i) \right)^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i)$$

$$= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \Phi^T(x_i) \Phi(x_j)$$

SMO: 序列最小最优化算法

$$\alpha^* = \arg \max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \phi^T(x_i) \phi(x_j) \right)$$

线性可分支持向量机学习算法

- 构造并求解约束最优化问题

$$\alpha^* = \arg \max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \varphi^T(x_i) \varphi(x_j) \right)$$

- 求得最优解 α^*

$$s. t. \sum_{i=1}^n \alpha_i y_i = 0 \quad \alpha_i \geq 0, i = 1, 2, \dots, n$$

- 计算

$$w^* = \sum_{i=1}^n \alpha_i^* y_i \varphi(x_i) \quad b^* = y_i - \sum_{i=1}^n \alpha_i^* y_i (\varphi(x_i) \cdot \varphi(x_j))$$

- 求得分离超平面


$$w^* \varphi(x) + b^* = 0$$

- 分类决策函数

$$f(x) = \text{sign}(w^* \varphi(x) + b^*)$$

线性支持向量机

- 不一定分类完全正确的超平面就是最好的
- 样本数据本身线性不可分



线性支持向量机

- 若数据线性不可分，则增加松弛因子 $\xi_i \geq 0$ ，使函数间隔加上松弛变量大于等于1.这样。约束条件变成：

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i$$

- 目标函数：

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

$$\begin{aligned} s. t. \quad & y_i(w \cdot x_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, n \\ & \xi_i \geq 0, i = 1, 2, \dots, n \end{aligned}$$

求解最终的目标函数

■ 拉格朗日函数

$$L(w, b, \xi, \alpha, \mu) \stackrel{\text{def}}{=} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i (y_i (w^T \cdot \varphi(x_i) + b) - 1 + \xi_i) - \sum_{i=1}^n \mu_i \xi_i$$

■ 对 w, b, ξ 求偏导

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i \varphi(x_i)$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow 0 = \sum_{i=1}^n \alpha_i y_i$$

$$\frac{\partial L}{\partial \xi_i} = 0 \Rightarrow C - \alpha_i - \mu_i = 0$$

带入目标函数

- 将三式带入L中，得到：

$$\min_{w,b,\xi} L(w,b,\xi,\alpha,\mu) \stackrel{\text{def}}{=} -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \alpha_i$$

- 对上式求关于 α 的极大，得到：

$$\begin{aligned} \max_{\alpha} & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \alpha_i \\ \text{s.t.} & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \end{aligned}$$

最终的目标函数

■ 整理，得到对偶问题：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \end{aligned}$$

线性支持向量机学习算法

- 构造并求解约束最优化题：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \end{aligned}$$

- 求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_n^*)^T$

线性支持向量机学习算法

■ 计算

$$w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$$

选择 α^* 的一个分量 α_j^* 适合条件 $0 \leq \alpha_j^* \leq C$, 计算

$$b^* = y_i - \sum_{i=1}^n \alpha_i^* y_i (x_i \cdot x_j)$$



■ 求得分离超平面

$$w^* \varphi(x) + b^* = 0$$

■ 分类决策函数

$$f(x) = \text{sign}(w^* x + b^*)$$

非线性支持向量机



什么是核函数?

核函数：设 χ 是输入空间，又设 H 为特征空间，如果存在一个从 χ 到 H 的映射

$$\varphi(x): \chi \rightarrow H$$

使得对所有 $x, z \in \chi$ ，函数 $K(x, z)$ 满足条件

$$K(x, z) = \varphi(x) \cdot \varphi(z)$$

则称 $K(x, z)$ 为核函数， $\varphi(x)$ 为映射函数，式中 $\varphi(x) \cdot \varphi(z)$ 为 $\varphi(x)$ 和 $\varphi(z)$ 的内积。

常见的核函数

- 多项式核函数:

$$K(x_i, x_j) = (x_i \cdot x_j + c)^d$$

- 高斯核函数:

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

- 在实际应用中，往往依赖先验领域的知识、交叉验证等方法才能选择有效的核函数。
 - 如果没有更多的先验信息，则使用高斯核函数

多项式核函数

$$K(\vec{x}, \vec{y}) = (\vec{x} \cdot \vec{y} + c)^2$$

$$\Rightarrow (\vec{x} \cdot \vec{y})^2 + 2c\vec{x} \cdot \vec{y} + c^2$$

$$= \sum_{i=1}^n \sum_{j=1}^n (x_i x_j)(y_i y_j) + \sum_{i=1}^n (\sqrt{2c}x_i \cdot \sqrt{2c}x_j) + c^2$$

例子：若n=3, 即： $\varphi(\vec{x}) = \begin{pmatrix} x_1 x_1 \\ x_1 x_2 \\ x_1 x_3 \\ x_2 x_1 \\ x_2 x_2 \\ x_2 x_3 \\ x_3 x_1 \\ x_3 x_2 \\ x_3 x_3 \\ \sqrt{2c}x_1 \\ \sqrt{2c}x_2 \\ \sqrt{2c}x_3 \\ c \end{pmatrix}$

高斯核函数

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots + \frac{x^n}{n!} + R_n$$

$$\begin{aligned} \kappa(x_1, x_2) &= e^{-\frac{\|x_1 - x_2\|^2}{2\sigma^2}} = e^{-\frac{(x_1 - x_2)^2}{2\sigma^2}} = e^{-\frac{x_1^2 + x_2^2 - 2x_1x_2}{2\sigma^2}} = e^{-\frac{x_1^2 + x_2^2}{2\sigma^2}} \cdot e^{\frac{x_1x_2}{\sigma^2}} \\ &= e^{-\frac{x_1^2 + x_2^2}{2\sigma^2}} \cdot \left(1 + \frac{1}{\sigma^2} \cdot \frac{x_1x_2}{1!} + \left(\frac{1}{\sigma^2}\right)^2 \cdot \frac{(x_1x_2)^2}{2!} + \left(\frac{1}{\sigma^2}\right)^3 \cdot \frac{(x_1x_2)^3}{3!} + \cdots + \left(\frac{1}{\sigma^2}\right)^n \cdot \frac{(x_1x_2)^n}{n!} + \cdots \right) \\ &= e^{-\frac{x_1^2 + x_2^2}{2\sigma^2}} \cdot \left(1 \cdot 1 + \frac{1}{1!} \cdot \frac{x_1}{\sigma} \cdot \frac{x_2}{\sigma} + \frac{1}{2!} \cdot \frac{x_1^2}{\sigma^2} \cdot \frac{x_2^2}{\sigma^2} + \frac{1}{3!} \cdot \frac{x_1^3}{\sigma^3} \cdot \frac{x_2^3}{\sigma^3} + \cdots + \frac{1}{n!} \cdot \frac{x_1^n}{\sigma^n} \cdot \frac{x_2^n}{\sigma^n} + \cdots \right) \\ &= \Phi(x_1)^T \cdot \Phi(x_2) \end{aligned}$$

□ 其中 $\Phi(x) = e^{-\frac{x^2}{2\sigma^2}} \left(1, \sqrt{\frac{1}{1!}} \frac{x}{\sigma}, \sqrt{\frac{1}{2!}} \frac{x^2}{\sigma^2}, \sqrt{\frac{1}{3!}} \frac{x^3}{\sigma^3}, \cdots, \sqrt{\frac{1}{n!}} \frac{x^n}{\sigma^n}, \cdots \right)$

核函数在支持向量的应用

在线性支持向量机的对偶问题中，无论是目标函数还是决策函数，都只涉及输入实例与实例之间的内积。在**对偶问题的目标函数中的内积** $x_i \cdot x_j$ **可以用核函数** $K(x_i, x_j) = \varphi(x_i) \cdot \varphi(x_j)$ **来代替**。此时对偶问题的目标函数为：

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^n \alpha_i$$

非线性支持向量机学习算法

- 选取适当的核函数 $K(x, z)$ 和合适的参数 C ，构造并求解约束最优化题：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \end{aligned}$$

- 求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_n^*)^T$

非线性支持向量机器学习算法

■ 计算

$$w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$$

选择 α^* 的一个正分量适合条件 $0 < \alpha_j^* < C$ ，计算

$$b^* = y_i - \sum_{i=1}^n \alpha_i^* y_i K(x_i, x_j)$$

■ 分类决策函数

$$f(x) = \text{sign}(\sum_{i=1}^n \alpha_i^* y_i K(x, x_i) + b^*)$$

实验

- Python sklearn
- 手写字体识别

谢 谢