

# 机器学习讨论班

---

2018年暑期

# 其他回归方法

---

王紫悦

# 线性回归


给定数据集 $D=\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ , 其中 $x_i=(x_{i1}; x_{i2}; \dots; x_{id})$   
线性回归试图学得:

$$y_i = \hat{w}x_i + b$$

# 最小二乘法


$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1d} & 1 \\ x_{21} & x_{22} & \dots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{md} & 1 \end{bmatrix} \quad W = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \\ b \end{bmatrix} \quad Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

线性模型  $y_i = \hat{w}x_i + b$



$$Y = XW$$

均方误差  $e = \sum_{i=1}^m (y_i - \hat{w}x_i - b)^2$



$$E = \|Y - XW\|^2 \\ = (Y - XW)(Y - XW)^T$$

# 最小二乘法

欲求均方误差最小，对 $W$ 求导，得： $\frac{\partial E}{\partial W} = 2X^T(XW - Y)$

当 $X^T X$ 为满秩矩阵或正定矩阵，令上式为0，得：

$$W = (X^T X)^{-1} X^T Y$$

可逆？

现实任务中 $X^T X$ 往往不是满秩矩阵。比如，许多任务中有大量的变量，其数目超过样例数，导致 $X$ 的列数大于行数。此时可解出多个 $W$ ，导致结果不稳定。

引入正则项

# 正则化

思路：在原先的W的最小二乘估计中加入正则项  $\lambda I$ ，使问题得以解决。

$$W(\lambda) = (X^T X + \lambda I)^{-1} X^T Y$$

$$(\hat{w}, b) = \operatorname{argmin}_{\hat{w}, b} \left\{ \sum_{i=1}^m \left( y_i - \sum_{j=1}^d x_{ij} w_j - b \right)^2 + \lambda \sum_{j=1}^d |w_j|^q \right\}$$


约束项

# 介绍内容

- 岭回归
- Lasso回归
- 弹性网络

# 岭回归(Ridge Regression,RR)

$$(\hat{w}, b) = \operatorname{argmin}_{\hat{w}, b} \left\{ \sum_{i=1}^m \left( y_i - \sum_{j=1}^d x_{ij} w_j - b \right)^2 + \lambda \sum_{j=1}^d w_j^2 \right\}$$





$$(\hat{w}, b) = \operatorname{argmin}_{\hat{w}, b} \sum_{i=1}^m \left( y_i - \sum_{j=1}^d x_{ij} w_j - b \right)^2$$

$$\text{subject to } \sum_{j=1}^d w_j^2 \leq t$$



# RR几何意义




# 岭迹图

岭迹图作用：

1) 观察  $\lambda$  较佳取值；  
一般通过观察，选取喇叭口附近的值，此时各  $w$  值已趋于稳定，但总的RSS又不是很大。


2) 观察变量是否有多重共线性  
岭迹波动大，说明该变量参数有共线性

3) 选择变量  
删除那些  $w$  取值一直趋于0的变量。



# RR参数选择原则

1. 各回归系数的岭估计基本稳定
2. 用最小二乘估计时符号不合理的回归系数，其岭估计的符号变得合理
3. 回归系数没有不合乎实际意义的绝对值
4. 残差平方和增大不太多




# RR的问题

- 岭参数计算方法太多，差异太大
- 若不经过变量筛选，岭回归返回的模型包含所有变量
- 根据岭迹图进行变量筛选，随意性太大

# LASSO回归


$$(\hat{w}, b) = \operatorname{argmin}_{\hat{w}, b} \left\{ \sum_{i=1}^m \left( y_i - \sum_{j=1}^d x_{ij} w_j - b \right)^2 + \lambda \sum_{j=1}^d |w_j| \right\}$$



$$(\hat{w}, b) = \operatorname{argmin}_{\hat{w}, b} \sum_{i=1}^m \left( y_i - \sum_{j=1}^d x_{ij} w_j - b \right)^2$$


*subject to*  $\sum_{j=1}^d |w_j| \leq t$

# LASSO回归




# LASSO VS RR

岭回归



LASSO



# LASSO VS RR

LASSO回归	岭回归
L1范式 $ w $	L2范式 $w^2$
使部分系数缩小为0	使所有系数收缩趋向于0
筛选变量	消除共线性



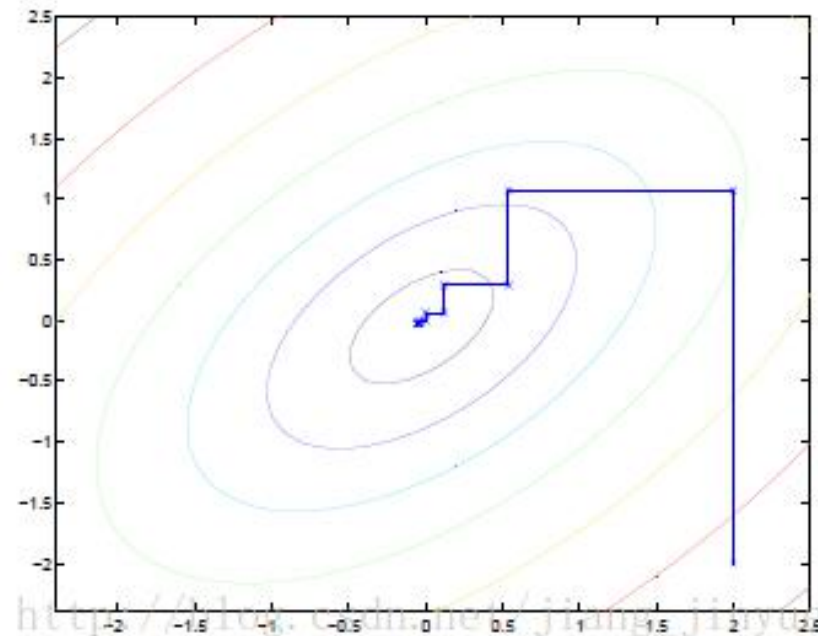
# LASSO计算方法

- 坐标轴下降法 (Coordinate descent)
- 最小角回归法 (Least Angle Regression)

# 坐标轴下降法 (Coordinate descent)

求解步骤:


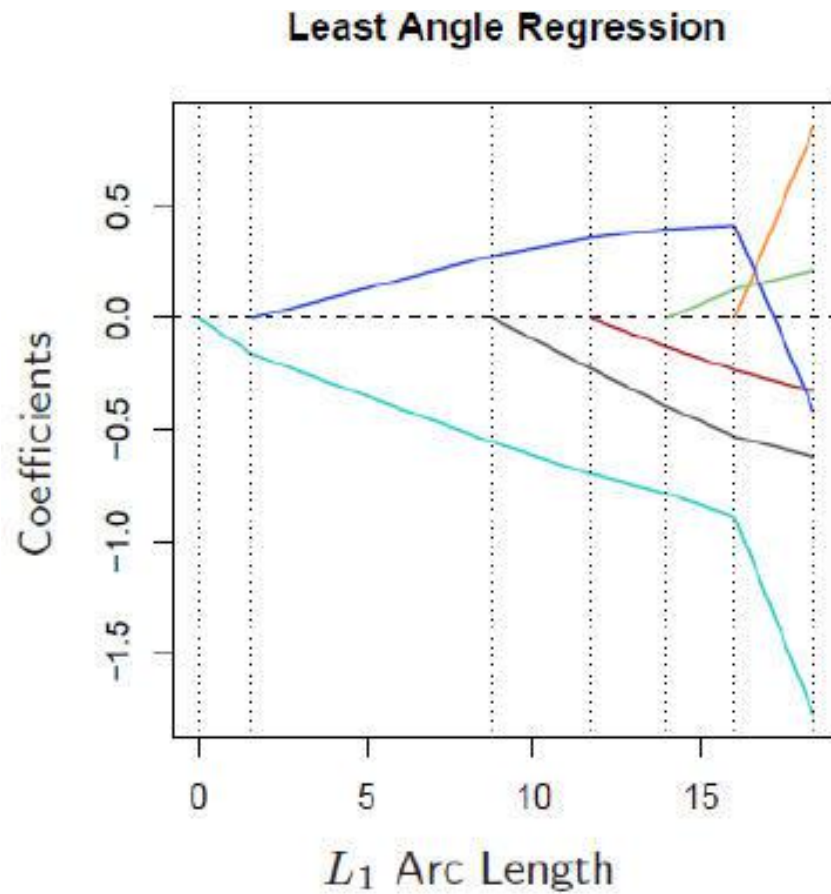
1. 给定初始点  $(x_1, x_2, \dots, x_n)$
2. 固定除  $x_i$  以外其他维度的点, 以  $x_i$  为自变量获取最小值
3. 换个维度, 重复2



# LASSO计算方法

- 坐标轴下降法 (Coordinate descent)
- 最小角回归法 (Least Angle Regression)

# 最小角回归LAR




# 最小角回归LAR

思想：

LAR是每次先找出和因变量相关度最高的那个变量, 再沿着LSE的方向一点点调整其相关系数, 在这个过程中, 这个变量和残差的相关系数会逐渐减小, 等到这个相关性没那么显著的时候, 就要选进新的相关性最高的变量, 然后重新沿着LSE的方向进行变动。而到最后, 所有变量都被选中, 就和LSE相同了。

# 最小角回归LAR

- 1) 找到和Y向量夹角最小的向量X1，记最初夹角为角1。Y与X1的局部最小二乘解为Y到X1的距离。从原点出发，沿着X1，向这个局部最小二乘解移动。
- 2) 在这个变化的过程中，总有某一时刻，另一个变量X2与r之间的相关系数，与X1和r之间的相关系数一样大。这个时候把X2加入，前进的方向修正为r与X2夹角的角平分线方向



# 最小角回归LAR

优点:

- 1) 特别适合于特征维度 $n$  远高于样本数 $m$ 的情况
- 2) 算法的最坏计算复杂度和最小二乘法类似, 但是其计算速度几乎和前向选择算法一样
- 3) 可以产生分段线性结果的完整路径, 这在模型的交叉验证中极为有用

缺点:

由于LAR的方向是根据目标的残差而定, 所以该算法对样本的噪声极为敏感。

# LASSO回归

- 对数据要求低，应用程度广
- 收缩系数，筛选变量
- 降低模型复杂度



# 弹性网络 (Elastic Net)

一种使用L1和L2先验作为正则化矩阵的线性回归模型

岭回归和lasso回归的结合

用于只有很少的权重非零的稀疏模型

$$(\hat{w}, b) = \operatorname{argmin}_{\hat{w}, b} \left\{ \sum_{i=1}^m \left( y_i - \sum_{j=1}^d x_{ij} w_j - b \right)^2 + \lambda \sum_{j=1}^d \left[ \alpha w_j^2 + (1 - \alpha) |w_j| \right] \right\}$$

# 弹性网络 (Elastic Net)

岭回归	一定程度上可以拟合模型，但回归结果易失真
LASSO回归	刻画模型代表的现实情况，但模型过于简单，不符实际
弹性网络	达到对重要特征选择的目的，删除对因变量影响较小的特征

# 课后练习

sklearn包，利用交叉验证法确定参数、带cv校准过程的回归模型

岭回归 : [linear\\_model.RidgeCV](#)

LASSO : [LassoCV and LassoLarsCV](#)

弹性网络: [ElasticNetCV](#)

谢 谢