

# 机器学习讨论班

---

2018年暑期

# 度量学习

## (DISTANCE) METRIC LEARNING

刘宾楚

09/12/2018

# 度量学习的定义：

- 降维的目的：在高维空间中，找到一个合适的低维空间，从而在低维空间中进行学习能够获得更好的性能。
- 降维的实质：每一个不同的空间都对应不同的距离度量，寻找合适的低维空间，实际就是寻找合适的度量。
- 度量学习的基本动机：通过学习，直接得出合适的距离度量。
- 度量学习 与 降维：密切相关

# 距离度量

## ■四个条件:

□  $d(x; y) \geq 0$  , 非负性

□  $d(x; y) = d(y; x)$  , 对称性

□  $d(x; y) = 0 \leftrightarrow x = y$  , 同一性/自反性

□ (不存在两个不同实体, 其所有属性全部相同)

□  $d(x; z) \leq d(x; y) + d(y; z)$  , 三角不等式

# 距离度量

■  $l_p$  范数 与  $l_p$  距离:

■  $l_p$  范数:  $\|x\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}, \quad p \geq 1$

■ 当  $0 \leq p \leq 1$  时, 不是范数, 不满足三角不等式

■  $l_0$  范数: 通常用作表示  $x$  中 非0元素的个数, 但不是有效的范数。

■ 当  $p \geq 1$ ,  $l_p$  范数 可以用作距离:  $d_p(x, y) = \|x - y\|_p$

■  $p = 1$  街区距离  $p = 2$  欧式距离

# 距离度量

- 度量学习需要
  - 1. 非固定 2. 具有可调节参数 的距离度量
  - 非标准马氏距离
- 马氏距离由印度统计学家马哈拉诺比斯(P. C. Mahalanobis)提出
- 与欧氏距离不同的是它考虑到各种特性之间的联系。--- 协方差
- 表示数据的协方差距离：通过分解协方差矩阵 得到新的坐标基 （P9）
- 它是一种有效的计算两个未知样本集(分布之间)的相似度的方法

$$d(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T S^{-1} (\vec{x} - \vec{y})}.$$

# 距离度量

- 平方欧式距离： 单位阵

$$\text{dist}_{\text{ed}}^2(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = \text{dist}_{ij,1}^2 + \text{dist}_{ij,2}^2 + \dots + \text{dist}_{ij,d}^2 ,$$

- 引入权重： 对角阵

$$\begin{aligned} \text{dist}_{\text{wed}}^2(\mathbf{x}_i, \mathbf{x}_j) &= \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = w_1 \cdot \text{dist}_{ij,1}^2 + w_2 \cdot \text{dist}_{ij,2}^2 + \dots + w_d \cdot \text{dist}_{ij,d}^2 \\ &= (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{W} (\mathbf{x}_i - \mathbf{x}_j) , \end{aligned} \quad (10.33)$$

- 非标准马氏距离： 半正定对称阵

$$\text{dist}_{\text{mah}}^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2 ,$$

# 马氏距离

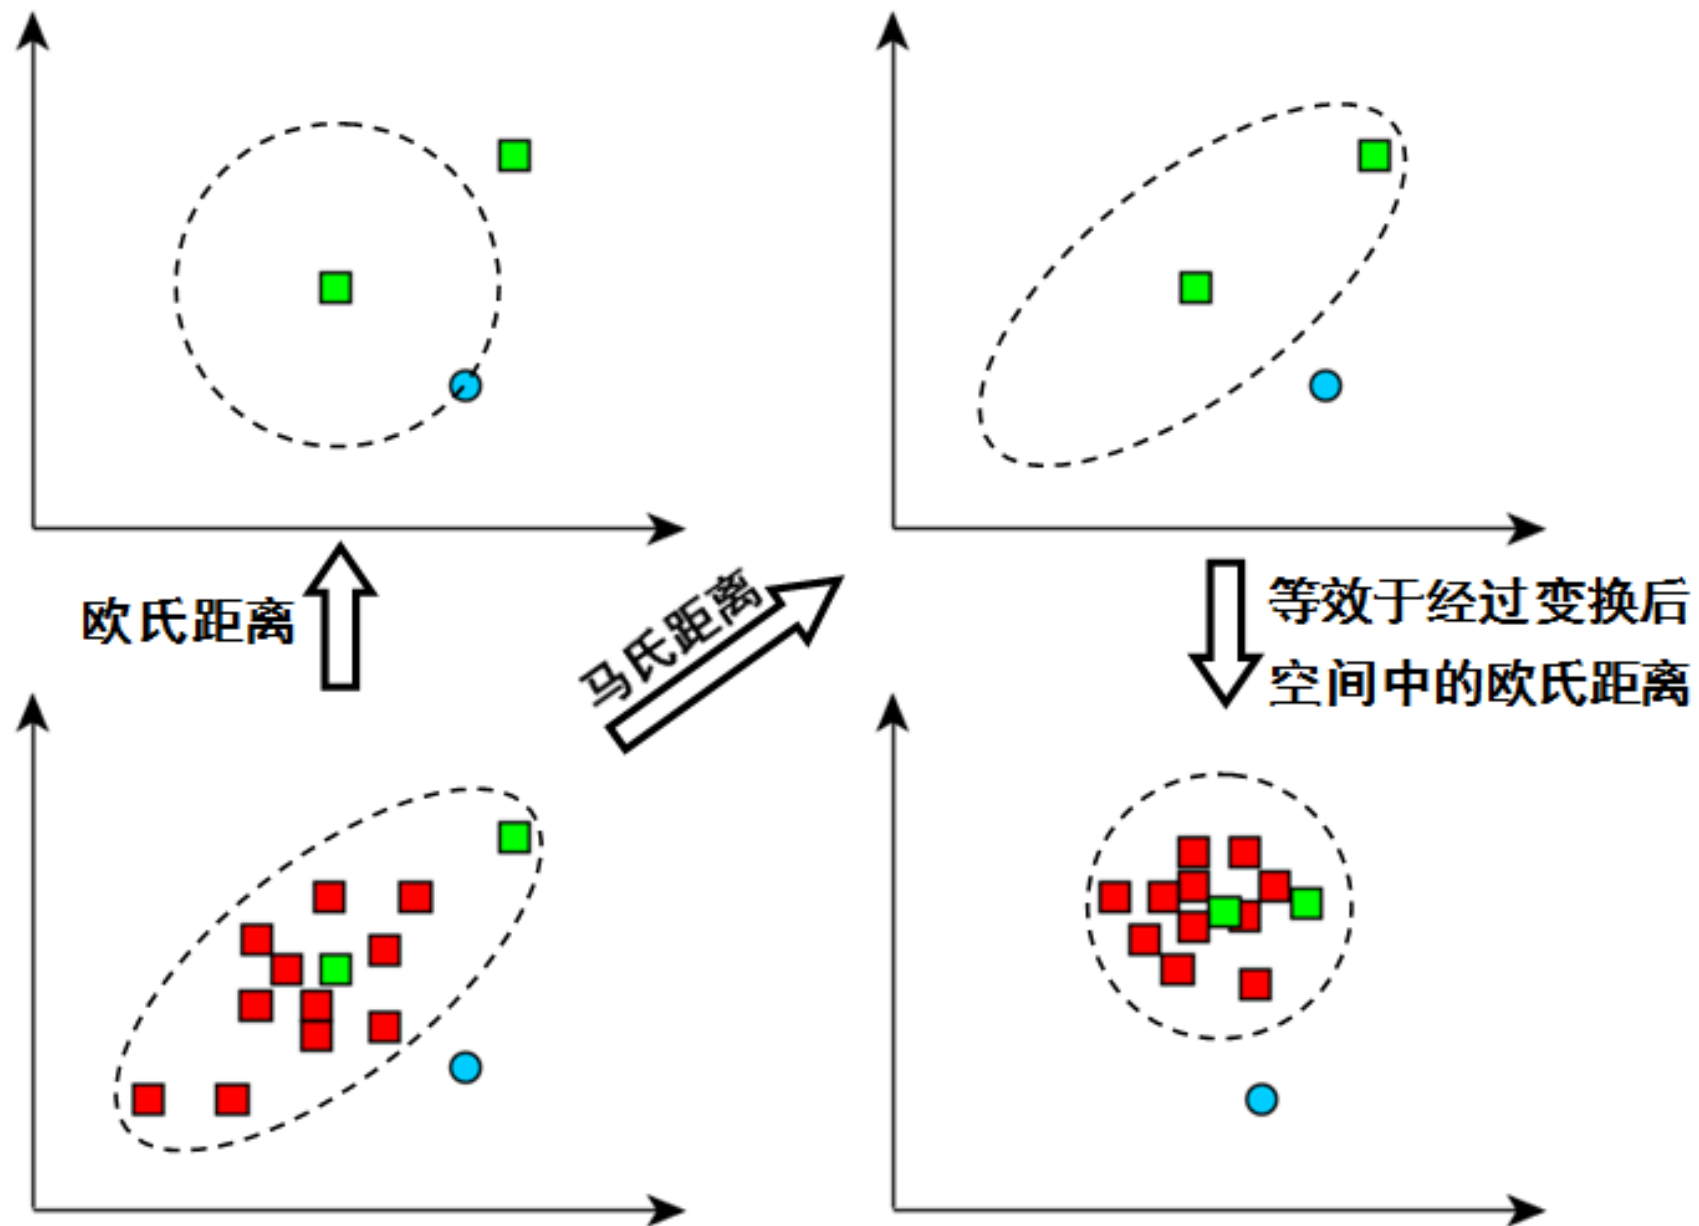
## ■ 优点:

- 不受量纲的影响
- 尺度无关
- 考虑到维度之间的相互关系

## ■ 缺点:

- 建立在总体样本的基础上
- 要求总体样本数大于样本的维数
- 马氏距离的计算 不稳定





# 再看 主成分分析 PCA

算法描述:

输入:  $n$ 维样本集  $D=(x_1, x_2, x_3, \dots, x_m)$ , 要降维到维数 $d'$ .



- 1) 对所有的样本进行中心化:  $x_i = x_i - \frac{1}{m} \sum_{i=1}^m x_i$ ;
- 2) 计算样本的协方差矩阵  $\mathbf{XX}^T$ ;
- 3) 对矩阵  $\mathbf{XX}^T$  进行特征值分解;
- 4) 取出最大的 $d'$ 个特征值对应的特征向量( $w_1, w_2, w_3, \dots, w_{d'}$ )

将所有的特征向量标准化后, 组成特征向量矩阵  $\mathbf{W}$ ;



- 5) 对样本集中的每一个样本, 转化为新的样本  $z_i = \mathbf{W}^T x_i$

输出: 得到输出样本集  $D' = (z_1, z_2, \dots, z_m)$ .


# 马氏距离对应的空间变换



# 马氏距离对应的空间变换



# 马氏距离对应的空间变换



# 近邻成分分析 NCA

- 目标：寻找合适的度量，提高近邻分类器的性能
- 方法：将度量矩阵  $\mathbf{M}$  嵌入近邻分类器的评价指标中，通过求解其最优值
- 对于任意样本  $x_j$ ，它对于  $x_i$  的分类结果的影响为：

$$p_{ij} = \frac{\exp\left(-\|x_i - x_j\|_{\mathbf{M}}^2\right)}{\sum_l \exp\left(-\|x_i - x_l\|_{\mathbf{M}}^2\right)},$$

- 分子:  $i$  和  $j$  两个样本点的马氏距离
- 分母: 所有点 距离  $i$  点的距离之和
- $x_j$  对  $x_i$  的影响随着它们之间距离的增大而减小

# 近邻成分分析 NCA

- $x_i$  的留一法正确率：被自身之外的所有样本分类正确的概率
  - $\Omega_i$  表示与  $x_i$  属于相同类别的样本的下标的集合

$$p_i = \sum_{j \in \Omega_i} p_{ij} ,$$

- 整个样本上的留一法正确率：

$$\sum_{i=1}^m p_i = \sum_{i=1}^m \sum_{j \in \Omega_i} p_{ij} .$$

- 度量矩阵  $M$  半正定对称 则必有 正交基  $P$  使得  $M = PP^T$

- 最优化目标：

$$\min_{\mathbf{P}} 1 - \sum_{i=1}^m \sum_{j \in \Omega_i} \frac{\exp \left( - \|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_j\|_2^2 \right)}{\sum_l \exp \left( - \|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_l\|_2^2 \right)} .$$

# 引入领域知识

- 如果已知某些样本相似，某些样本不相似，那么可以定义必连约束集合 $M$ 和勿连约束集合 $C$ 。
- 思想：希望相似的样本之间距离较小，不相似的样本之间距离较大。
- 最优化目标：

$$\begin{aligned} \min_{\mathbf{M}} \quad & \sum_{(\mathbf{x}_i, \mathbf{x}_j) \in M} \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2 \\ \text{s.t.} \quad & \sum_{(\mathbf{x}_i, \mathbf{x}_k) \in C} \|\mathbf{x}_i - \mathbf{x}_k\|_{\mathbf{M}}^2 \geq 1, \end{aligned}$$

- $M \geq 0$  表示  $M$  必须是半正定  $\mathbf{M} \succeq 0$  ,
  - E. P. Xing, A. Y. Ng, M. I. Jordan, and S. Russell. Distance metric learning with application to clustering with sideinformation. In: NIPS, pages 505-512, 2003



# 度量学习的分类

- <http://www.cs.cmu.edu/~liuy/distlearn.htm>
- [A comprehensive survey on distance metric learning](#)
- [An overview of distance metric learning](#)
- 有监督的度量学习：
  - 全局：同时满足所有的必连和勿连约束
    - Relevant Components Analysis (RCA) 线性
    - Discriminative Component Analysis (DCA) 线性
  - 局部：不必满足所有的约束 仅满足附近的约束
    - Local Fisher Discriminant Analysis (LFDA) 线性
    - Neighborhood Component Analysis (NCA) 线性

# 无监督的度量学习

- 保留全局信息
  - Principal Component Analysis(PCA) 线性
  - Multidimensional Scaling(MDS) 线性
  - ISOMAP 非线性
- 保留局部信息
  - Laplacian Eigenmap (LE) 非线性
  - Locality Preserving Projections (LPP) 线性
  - Locally Linear Embedding (LLE) 非线性
  - Neighborhood Preserving Embedding (NPE) 线性

# 度量学习 与 降维

- 不同的度量学习方法 针对 不同的目标 获得 “好” 半正定 距离度量矩阵 $M$ ,
- 通过对 度量矩阵 进行 特征值分解
- 总能够找到一组 正交基 作为新空间中的坐标基
  - 若 $M$ 是一个低秩矩阵, 那么
  - 正交基的数目小于矩阵维数 --- 降维
- 一个问题 从不同角度考虑, 一体两面

# 度量学习

- $l_p$  距离 与 马氏距离
- 马氏距离 对应的 投影变换 – PCA
- 近邻成分分析 NCA
- 引入领域知识的度量学习
- 度量学习 同 降维 的关系
- 度量学习 的拓扑分类

谢 谢